Probabilidade e Estatística - QUIZ 5

Instituto Tecnológico de Aeronáutica

Alexandre A. A. M. de Abreu



1. Distribuição Normal

A amostra de dados para realização dos testes de normalidade é apresentada a seguir:

```
dados <- c(149.3355, 140.3779, 145.7254, 149.8931, 139.6168, 149.1934,

□ 129.6147, 134.7523, 167.8030, 171.7407, 157.5422, 160.2664,

□ 155.4553, 142.5989, 134.9844, 148.5172, 163.1447, 131.0138,

□ 130.2423, 167.2239, 149.4015, 145.6802, 160.3472, 121.1775,

□ 136.7295, 162.2381, 150.7192, 117.8144, 137.3630, 158.6373,

□ 168.0833, 133.9263, 150.9102, 149.4811, 167.4367, 178.0970,

□ 138.4903, 148.6764, 181.0990, 167.3345, 147.0679, 156.1410,

□ 148.8734, 140.9484, 147.6408, 134.5726, 184.6812, 134.6648,

□ 146.8130, 167.4161)

z.dados <- scale(dados)
```

a) Testes de Normalidade

i) Kolmogorov-Smirnov

```
ks.test(z.dados, "pnorm", 0, 1)
```

One-sample Kolmogorov-Smirnov test data: z.dados D = 0.1167, p-value = 0.4688 alternative hypothesis: two-sided ii) Shapiro-Wilk shapiro.test(dados) Shapiro-Wilk normality test data: dados W = 0.98185, p-value = 0.6324 iii) Anderson-Darlin library(nortest) ad.test(dados) Anderson-Darling normality test data: dados A = 0.37902, p-value = 0.3928 iv) Lilliefors lillie.test(dados)

Lilliefors (Kolmogorov-Smirnov) normality test

data: dados

D = 0.1167, p-value = 0.08619

Interpretação dos resultados:

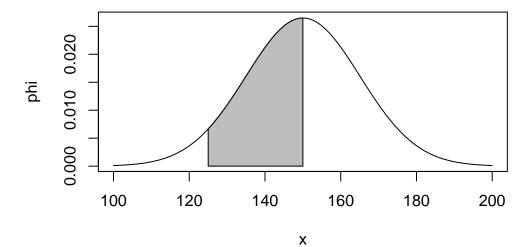
Considerando um nível de significância de 5%, não se rejeita a hipótese de que os dados amostrais seguem a distrição normal, pois os p-valores são maiores do que 0,05 para todos os testes de normalidade realizados anteriormente.

b) Probabilidade de que uma chamada demore entre 125 e 150 segundos.

```
media <- mean(dados)
sigma <- sd(dados)
z1 <- (125 - media) / sigma
z2 <- (150 - media) / sigma
probabilidade <- pnorm(z2) - pnorm(z1)
probabilidade</pre>
```

[1] 0.4509603

```
phi <- function(x) {
    (1/(sigma*sqrt(2*pi))) *exp((-1/2)*((x-media)/sigma)^2)
}
x = c(125, seq(125, 150, l=100), 150)
y = c(0, phi(seq(125, 150, l=100)), 0)
plot(phi, 100, 200)
polygon(x = x, y = y, col="gray")</pre>
```



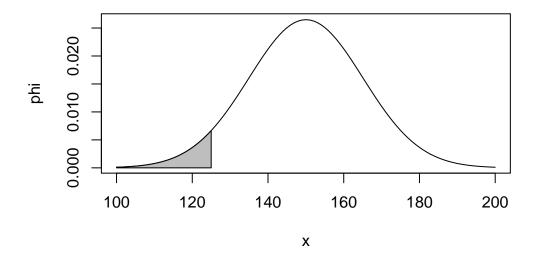
A probabilidade de que uma chamada demore entre 125 e 150 segundos é de 45,09603%.

c) Probabilidade de que uma chamada demore menos de 125 segundos.

```
probabilidade <- integrate(phi, -Inf, 125)
probabilidade</pre>
```

0.04824296 with absolute error < 9e-05

```
x = c(100, seq(100, 125, l=100), 125)
y = c(0, phi(seq(100, 125, l=100)), 0)
plot(phi, 100, 200)
polygon(x = x, y = y, col="gray")
```



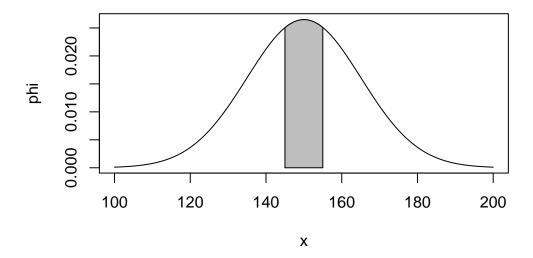
A probabilidade de que uma chamada demore menos de 125 segundos é de 4,824296%.

d) Probabilidade de que uma chamada demore entre 145 e 155 segundos.

```
z1 <- (145 - media) / sigma
z2 <- (155 - media) / sigma
probabilidade <- pnorm(z2) - pnorm(z1)
probabilidade</pre>
```

[1] 0.2601309

```
x = c(145, seq(145, 155, l=100), 155)
y = c(0, phi(seq(145, 155, l=100)), 0)
plot(phi, 100, 200)
polygon(x = x, y = y, col="gray")
```



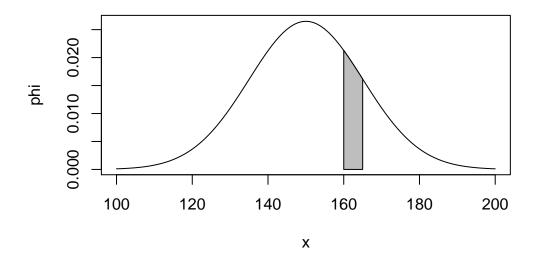
A probabilidade de que uma chamada demore entre 145 e 155 segundos é de 26,01309%.

e) Probabilidade de que uma chamada demore entre 160 e 165 segundos.

```
z1 <- (160 - media) / sigma
z2 <- (165 - media) / sigma
probabilidade <- pnorm(z2) - pnorm(z1)
probabilidade</pre>
```

[1] 0.09387641

```
x = c(160, seq(160, 165, l=100), 165)
y = c(0, phi(seq(160, 165, l=100)), 0)
plot(phi, 100, 200)
polygon(x = x, y = y, col="gray")
```



A probabilidade de que uma chamada demore entre 160 e 165 segundos é de 9,387641%.

2. Identificação de distribuição

Dados de uma variável aleatória X:

```
dados <- c(1.9993382, 1.4414849, 2.1477166, 2.1087828, 2.1342892,

□ 2.1844835, 1.5091879, 2.0467623, 1.0642741, 2.1302612, 1.8389897,

□ 1.8924614, 1.9316041, 1.5602204, 1.6991884, 1.7228081, 1.5197833,

□ 1.7659242, 0.6914335, 1.4598759, 2.0017607, 1.5139209, 1.8334780,

□ 1.8847480, 1.9072389, 1.6294414, 1.9068617, 1.7744973, 2.4300455,

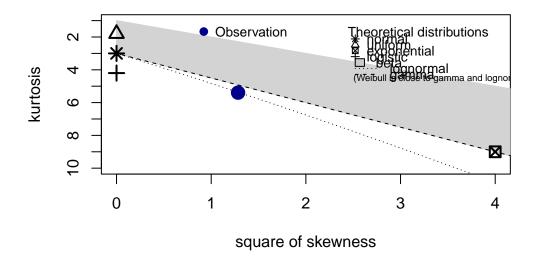
□ 1.8958270)
```

a) Faça a identificação da distribuição.

Pelo diagrama de Cullen e Frei, os dados parecem seguir uma distribuição Lognormal ou Weibull.

```
library(fitdistrplus)
library(logspline)
descdist(dados, discrete = FALSE)
```

Cullen and Frey graph



summary statistics

min: 0.6914335 max: 2.430045

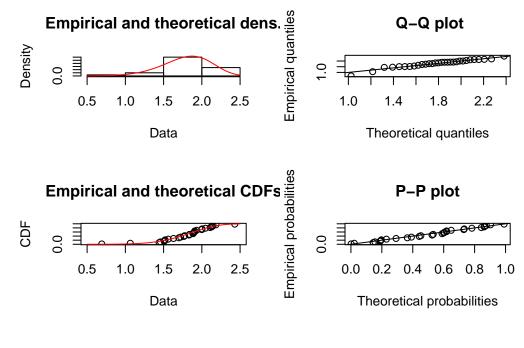
median: 1.861869 mean: 1.787556

estimated sd: 0.3498879

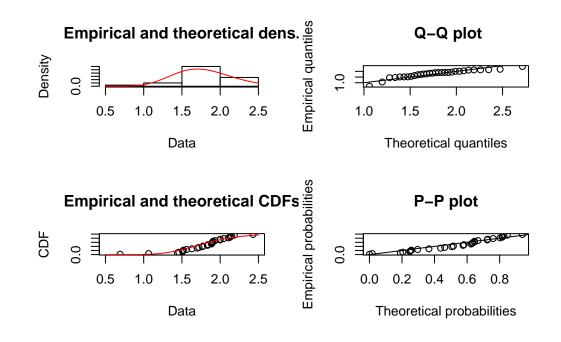
estimated skewness: -1.133072 estimated kurtosis: 5.391445

Os gráficos de ajuste de distribuição, dão indícios de que a distribuição Weibull é a que melhor se ajusta aos dados.

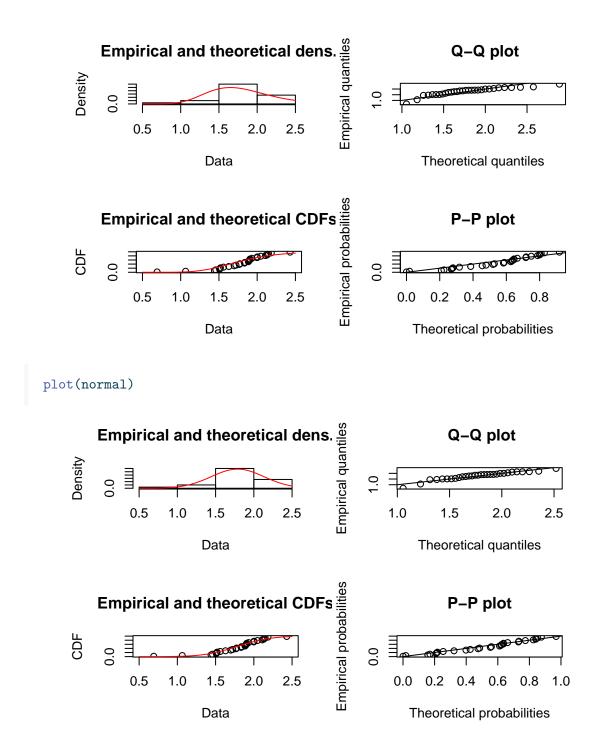
```
dados_norm <- (dados - min(dados))/(max(dados) - min(dados))
weibull <- fitdist(dados, "weibull")
gamma <- fitdist(dados, "gamma")
lognormal <- fitdist(dados, "lnorm")
normal <- fitdist(dados, "norm")
beta <- fitdist(dados_norm, "beta", method = "mme")</pre>
```



plot(gamma)



plot(lognormal)



O Critério de Informação de Akaike (AIC) confirma que **a distribuição Weibull** é a que melhor se ajusta aos dados. Seguem os valores:

```
cat(paste("Weibull: ", weibull$aic, "\nGamma: ", gamma$aic,
   → "\nLognormal: ", lognormal$aic, "\nNormal: ", normal$aic))
Weibull: 21.9771768698319
Gamma: 31.7072545492645
Lognormal: 36.1032950711012
Normal: 25.110725948175
Ajuste de distribuição e teste de Kolmogorov-Smirnov:
  mle <- fitdist(dados, "weibull", method="mle")</pre>
  mle$estimate
   shape
            scale
6.513198 1.918411
  ks.test(dados, "pweibull", shape = 6.513198, scale = 1.918411,
   ⇔ exact=FALSE)
    One-sample Kolmogorov-Smirnov test
data: dados
D = 0.091733, p-value = 0.9624
alternative hypothesis: two-sided
```

Portanto, com um nível de significância de 5%, não se rejeita a hipótese de que os dados se ajustem a uma distribuição Weibull, pois o p-valor é 0.9624.

b) Compare os resultados gerados pelo teste de Kolmogorov-Smirnov considerando as distribuições Gama, Lognormal e Weibull.

```
mle <- fitdist(dados, "gamma", method="mle")
mle</pre>
```

```
Fitting of the distribution 'gamma 'by maximum likelihood
Parameters:
      estimate Std. Error
shape 20.98456 5.375681
rate 11.73920 3.043447
  ks.test(dados, "pgamma", 20.98456, 11.73920, exact = FALSE)
    One-sample Kolmogorov-Smirnov test
data: dados
D = 0.14176, p-value = 0.5829
alternative hypothesis: two-sided
  mle <- fitdist(dados, "lnorm", method="mle")</pre>
  mle
Fitting of the distribution ' {\tt lnorm} ' by {\tt maximum} likelihood
Parameters:
         estimate Std. Error
meanlog 0.5568348 0.04322583
sdlog 0.2367576 0.03056282
  ks.test(dados, "plnorm", meanlog=0.5568348, sdlog=0.2367576,

→ exact=FALSE)

    One-sample Kolmogorov-Smirnov test
data: dados
D = 0.15513, p-value = 0.4658
alternative hypothesis: two-sided
```

```
mle <- fitdist(dados, "weibull", method="mle")
mle

Fitting of the distribution ' weibull ' by maximum likelihood
Parameters:
    estimate Std. Error
shape 6.513198 0.94665004
scale 1.918411 0.05622354

ks.test(dados, "pweibull", shape = 6.513198, scale = 1.918411,
    exact=FALSE)

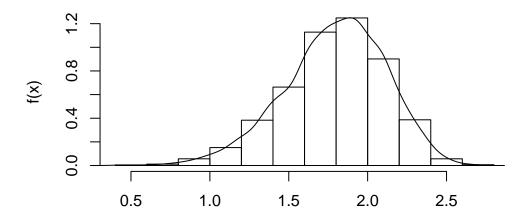
One-sample Kolmogorov-Smirnov test

data: dados
D = 0.091733, p-value = 0.9624
alternative hypothesis: two-sided</pre>
```

Todos os testes apresentaram p-valores que não justificam rejeitar as respectivas hipóteses nulas (que os dados seguem as distribuições Gamma, Normal e Weibull, respectivamente), com um nível de significância de 5%. Entretanto, a escolha da função de distribuição que melhor ajusta os dados é a Weibull, pois além de apresentar p-valor = 0.9624, é a que obteve melhor (menor) Critério de Informação de Akaike.

c) Plotar a função e o histograma para distribuição escolhida.

```
w_2_1 \leftarrow \text{rweibull}(3000, \text{ shape} = 6.513198, \text{ scale} = 1.918411)
\text{hist}(w_2_1, \text{lwd} = 1, \text{ ylab} = \text{"f}(x)\text{", xlab} = \text{"", freq} = F, \text{ main} = \text{""})
\text{lines}(x = \text{density}(w_2_1))
```



d) Verifique se a área sob a curva estimada é igual a 1.

```
w <- function(x, alpha = 6.513198, beta = 1.918411)

\Leftrightarrow {(alpha/(beta^alpha))*(x^(alpha-1))*(exp(-(x/beta)^alpha))}

x <- seq(0, 5, by = .01)

area <- integrate(w, 0, Inf)

area
```

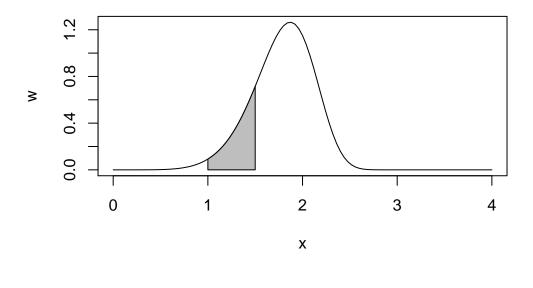
1 with absolute error < 3e-08

e) Para a distribuição escolhida, calcule a área gerada no intervalo [1; 1,5]. Plotar e destacar essa área.

```
a1 <- pweibull(1, shape = 6.513198, scale = 1.918411)
a2 <- pweibull(1.5, shape = 6.513198, scale = 1.918411)
probabilidade <- a2 - a1
probabilidade
```

[1] 0.1681586

```
q1 <- qweibull(a1, shape = 6.513198, scale = 1.918411)
q2 <- qweibull(a2, shape = 6.513198, scale = 1.918411)
x = c(q1, seq(q1, q2, l=100), q2)
y = c(0, w(seq(q1, q2, l=100)), 0)
plot(w, 0, 4)
polygon(x = x, y = y, col="gray")</pre>
```



3. Normalidade e intervalo de confiança

Amostra aleatória simples com os valores de inflação para os anos de 2013 a 2022 coletados do site do Banco Central do Brasil:

```
inflacao <- c(5.91, 6.41, 10.67, 6.29, 2.95, 3.75, 4.31, 4.52, 10.06,

→ 5.79)
```

a) Faça os testes de Shapiro-Wilk e de Lilliefors para verificar a normalidade. Qual é sua conclusão?

```
shapiro.test(inflacao)

Shapiro-Wilk normality test
data: inflacao
W = 0.88867, p-value = 0.1638

lillie.test(inflacao)
```

```
Lilliefors (Kolmogorov-Smirnov) normality test
```

```
data: inflacao
D = 0.24609, p-value = 0.08736
```

Considerando um nível de significância de 5%, não se rejeita a hipótese de que os dados amostrais de inflação seguem a distrição normal, considerando que ambos p-valores são maiores do que 0.05.

b) Usando esses dados, construa um intervalo de confiança de 99% para a média da inflação.

```
t.test(inflacao, conf.level = .99)
    One Sample t-test
data: inflacao
t = 7.5586, df = 9, p-value = 3.473e-05
alternative hypothesis: true mean is not equal to 0
99 percent confidence interval:
 3.457911 8.674089
sample estimates:
mean of x
    6.066
  x_bar <- mean(inflacao)</pre>
  s <- sd(inflacao)</pre>
  alpha <- 0.01
  n <- length(inflacao)</pre>
  gl <- n - 1
  t <- qt(alpha/2, gl, lower.tail = FALSE)
  LI <- x_bar - t*(s/(n^0.5))
  LS <- x_bar + t*(s/(n^0.5))
  cat(paste0("[", LI, ", ", LS, "]"))
```

[3.45791074446933, 8.67408925553067]

Portanto, pode-se afirmar com nível de confiaça de 99% que a média da inflação estará no intervalo $[3.457911,\,8.674089].$

c) Os especialistas têm a opinião de que o intervalo calculado para a média é muito amplo e querem um intervalo de comprimento total igual a 3. Encontre o nível de confiança para esse novo intervalo.

```
# Calcule o valor de t
t <- ((3/2) * sqrt(n)) / s
LI <- x_bar - t*(s/(n^0.5))
LS <- x_bar + t*(s/(n^0.5))
cat(paste0("Intervalo: [", LI, ", " , LS, "]"))

Intervalo: [4.566, 7.566]

alpha <- 2 * (pt(t, df = gl, lower.tail=FALSE))
alpha

[1] 0.09443553

c <- 1 - alpha
c</pre>
```

[1] 0.9055645

O intervalo [4.566,7.566] de comprimento total igual a 3 é obtido para um alpha = 0.09443553 e, portanto, o nível de confiança necessário é de 90,55645%.

d) Construa um intervalo de confiança de 90% para o desvio padrão.

```
c <- 0.9
q2_1 <- qchisq((1 - c) / 2, df = gl)
q2_2 <- qchisq(1 - (1 - c) / 2, df = gl)

# Intervalo de confiança para o desvio padrão</pre>
```

```
intervalo <- (n - 1) * s^2 / c(q2_2, q2_1) intervalo
```

[1] 3.426025 17.432443

Portanto, o intervalo de confiaça de 90% para média da amostra da inflação é $[3.426025\ 17.432443].$

e) Agora, teste a normalidade para toda a série histórica desde o início do regime de metas. Ou seja, utilize os dados de inflação efetiva de 1999 até 2022. Qual a conclusão?

```
inflacao <- c(8.94, 5.97, 7.67, 12.53, 9.3, 7.6, 5.69, 3.14, 4.46, 5.9,

4.31, 5.91, 6.5, 5.84, 5.91, 6.41, 10.67, 6.29, 2.95, 3.75, 4.31,

4.52, 10.06, 5.79)

length(inflacao)
```

[1] 24

Como a amostra tem menos de 30 observações, será utilizado o teste de Shapiro-Wilk.

```
shapiro.test(inflacao)
```

Shapiro-Wilk normality test

```
data: inflacao
W = 0.92757, p-value = 0.08602
```

Considerando um nível de significância de 5%, não rejeita-se a hipótese de que os dados da inflação para os anos de 1999 até 2022 seguem a distrição normal. É possível chegar na mesma conclusão aplicando-se os testes de Anderson-Darling e Kolmogorov-Smirnov.

```
ad.test(inflacao)
```

```
Anderson-Darling normality test

data: inflacao
A = 0.70952, p-value = 0.05561

ks.test(scale(inflacao), "pnorm", 0, 1)

One-sample Kolmogorov-Smirnov test

data: scale(inflacao)
D = 0.19749, p-value = 0.3065
alternative hypothesis: two-sided

lillie.test(inflacao)

Lilliefors (Kolmogorov-Smirnov) normality test

data: inflacao
D = 0.19749, p-value = 0.01631

Entretanto, pelo teste de Lilliefors (p-value = 0.01631), rejeita-se a hipótese de que os da-
```

dos da inflação para os anos de 1999 até 2022 seguem a distrição normal, com nível de 5% significância.

4. Identificação de distribuição

Identifique a distribuição de cada um dos conjuntos de dados mostrado a seguir.

a)

```
dados <- c(20.8625807, 7.2445709, 4.4659396, 3.2712081, 4.9300651,

        5.7444213, 6.6700987, 11.1750446, 2.3753017, 3.5425386, 0.5978486,

4 6.8869953, 6.1102197, 8.2716973, 9.7465462, 3.3991988, 1.8557047,
4 11.3983705, 3.6847590, 2.3327479, 6.1364329, 4.4686122, 7.8007834,
4.7649257, 3.8829371, 5.9986131, 5.5163819, 9.6951710, 10.1645820,

    6.1304865)

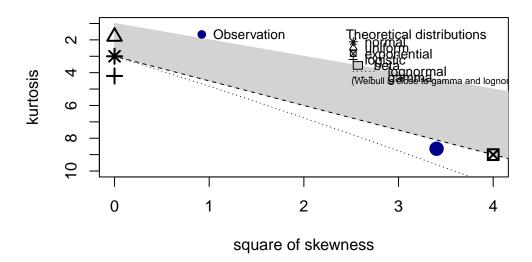
id_dist <- function (dados) {</pre>
 descdist(dados, discrete = FALSE)
 dados_norm <- (dados - min(dados)) / (max(dados) - min(dados))</pre>
 weibull <- fitdist(dados, "weibull", method="mle")</pre>
 gamma <- fitdist(dados, "gamma", method="mle")</pre>
 lognormal <- fitdist(dados, "lnorm", method="mle")</pre>
 normal <- fitdist(dados, "norm", method="mle")</pre>
 beta <- fitdist(dados_norm, "beta", method = "mme")</pre>
 uniforme <- fitdist(dados, "unif", method = "mle")</pre>
 exponencial <- fitdist(dados, "exp", method = "mle")</pre>
 logistica <- fitdist(dados, "logis", method = "mle")</pre>
 cat("Weibull: ")
 plot(weibull)
 cat("Gamma: ")
 plot(gamma)
 cat("Lognormal: ")
 plot(lognormal)
 cat("Normal: ")
 plot(normal)
 cat("Beta: ")
 plot(beta)
 cat("Uniforme: ")
 plot(uniforme)
 cat("Exponencial: ")
 plot(exponencial)
 cat("Logística: ")
```

```
plot(logistica)

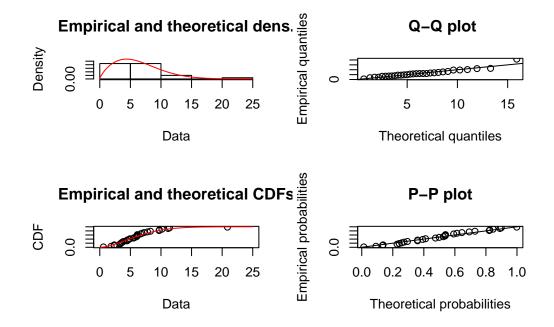
cat(paste("Critério de Informação de Akaike\n"))
cat(paste("Weibull: ", weibull$aic, "\n"))
cat(paste("Gamma: ", gamma$aic, "\n"))
cat(paste("Lognormal: ", lognormal$aic, "\n"))
cat(paste("Normal: ", normal$aic, "\n"))
cat(paste("Beta: ", beta$aic, "\n"))
cat(paste("Uniforme: ", uniforme$aic, "\n"))
cat(paste("Exponencial: ", exponencial$aic, "\n"))
cat(paste("Logística: ", logistica$aic, "\n"))
}

id_dist(dados);
```

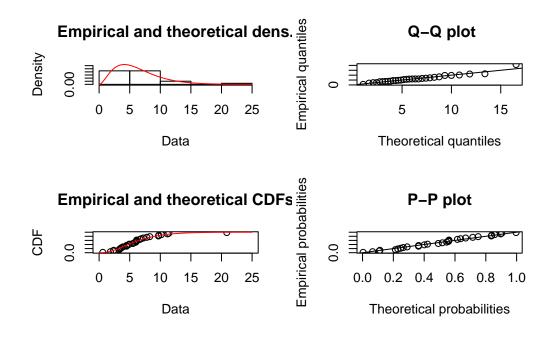
Cullen and Frey graph



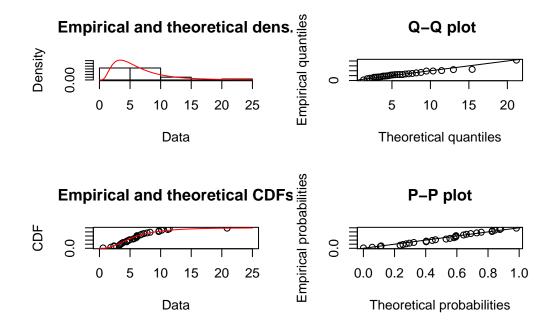
Weibull:



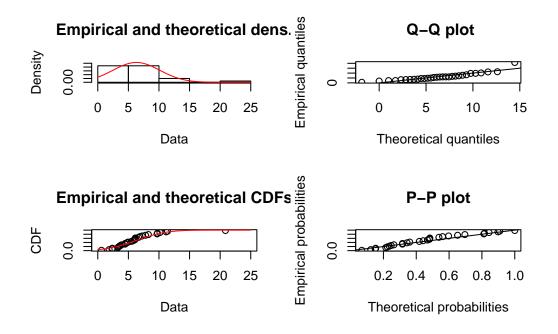
Gamma:



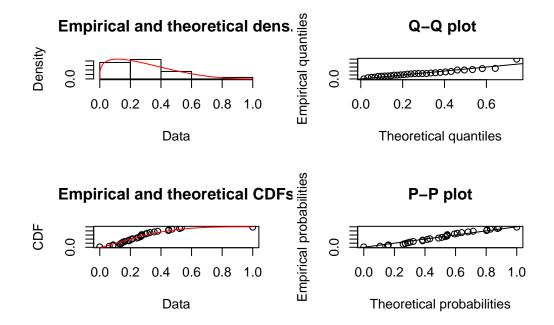
Lognormal:



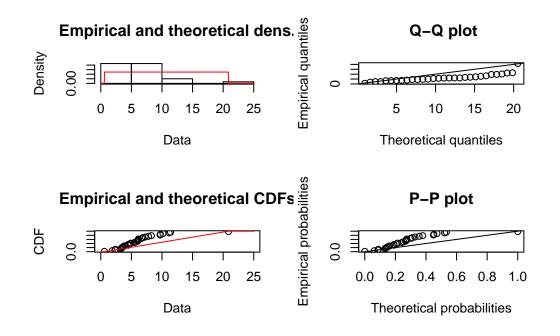
Normal:



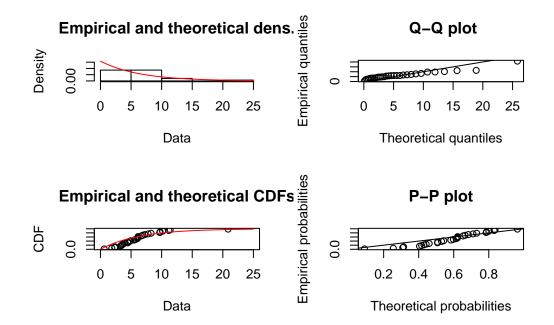
Beta:



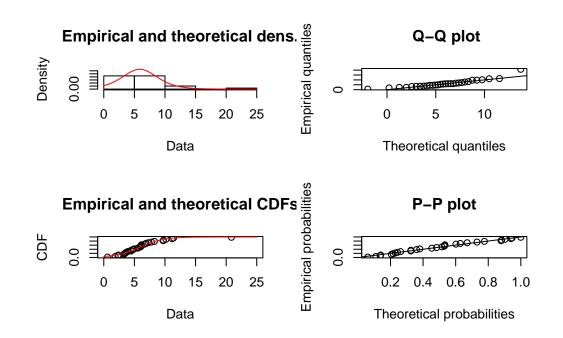
Uniforme:



Exponencial:



Logística:



Critério de Informação de Akaike

Weibull: 161.672292309238 Gamma: 160.373248793533 Lognormal: 163.258756195955 Normal: 169.773122301626

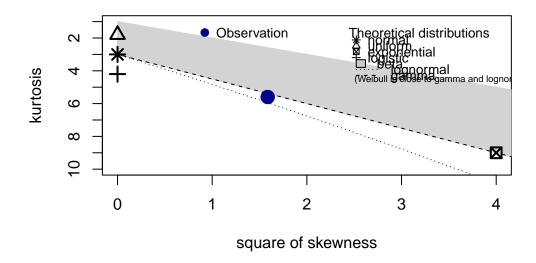
Beta: Inf

Uniforme: 184.532922409344 Exponencial: 172.47257861511 Logística: 164.7748413195

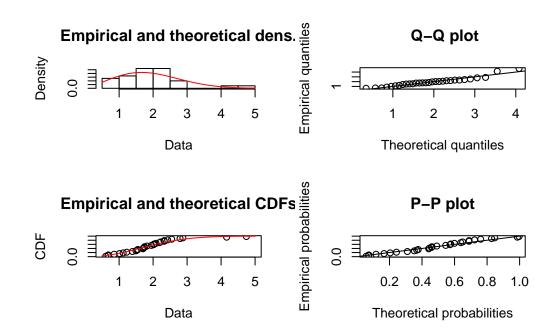
A distribuição que apresenta menor Critério de Informação de Akaike é a **Gamma**. Portanto, realiza-se o teste de Kolmogorov-Smirnov e não se rejeita a hipótese de que os dados seguem a distribuição **Gamma**, com um nível de significância de 5%.

```
fitdist(dados, "gamma", method="mle")
Fitting of the distribution 'gamma 'by maximum likelihood
Parameters:
      estimate Std. Error
shape 2.8718513 0.7027011
rate 0.4555631 0.1217956
  ks.test(dados, "pgamma", 2.8718513, 0.4555631, exact=FALSE)
    One-sample Kolmogorov-Smirnov test
data: dados
D = 0.079846, p-value = 0.9909
alternative hypothesis: two-sided
b)
  dados <- c(1.4940354, 2.0164275, 1.9513521, 1.5298282, 0.6815670,
   2.4267801, 0.6762800, 1.7018986, 4.1632638, 2.5472784, 2.2174151,
   4 0.6058986, 1.7432601, 1.1199216, 1.7135932, 2.8758657, 0.8537880,
   4 1.5511504, 2.3262178, 2.3267933, 1.3916375, 4.7439947, 2.1864812,
   2.0269031,1.7489244, 1.8191036, 2.0845146, 1.2229195, 1.0115042,
   id_dist(dados);
```

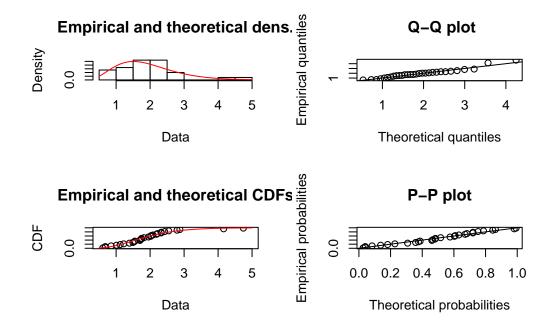
Cullen and Frey graph



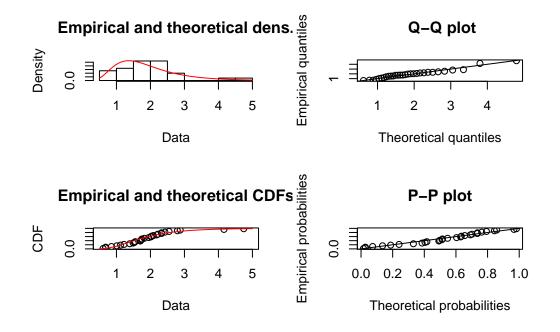
Weibull:



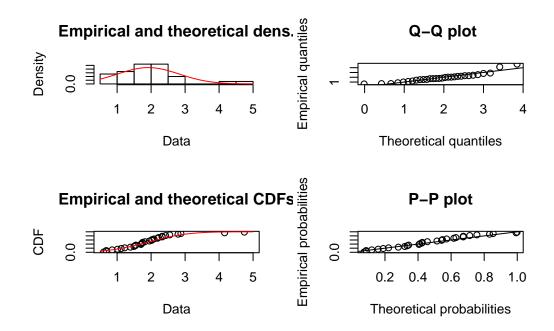
Gamma:



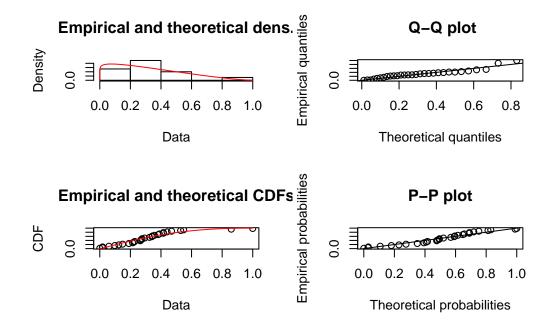
Lognormal:



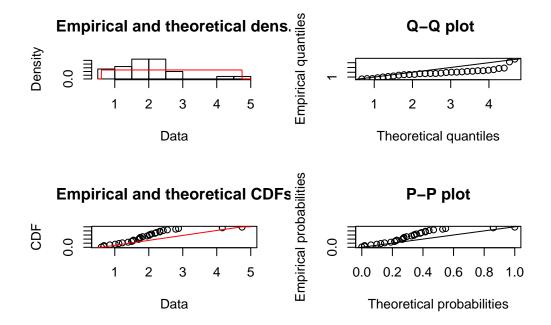
Normal:



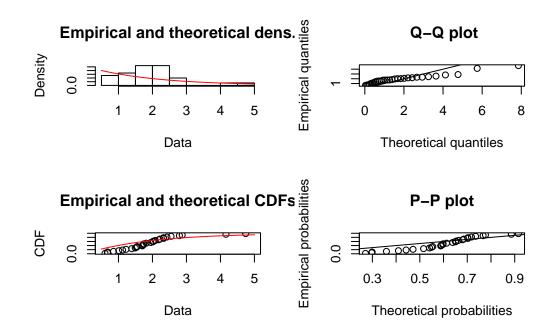
Beta:



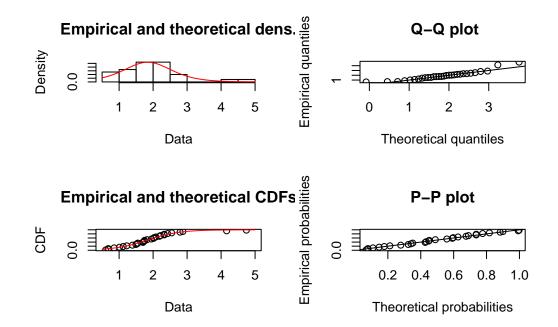
Uniforme:



Exponencial:



Logística:



Critério de Informação de Akaike

Weibull: 79.5774526646433 Gamma: 77.3266281106984 Lognormal: 77.8469359969155 Normal: 83.2772121593977

Beta: Inf

Uniforme: 89.2141481699972 Exponencial: 101.089198302578 Logística: 80.2541161161851

A distribuição que apresenta menor Critério de Informação de Akaike é a **Gamma**. Portanto, realiza-se o teste de Kolmogorov-Smirnov e não se rejeita a hipótese de que estes dados também seguem a distribuição **Gamma**, com um nível de significância de 5%.

```
fitdist(dados, "gamma", method="mle")
```

Fitting of the distribution ' gamma ' by maximum likelihood Parameters:

estimate Std. Error shape 4.697015 1.1722338 rate 2.448444 0.6449308

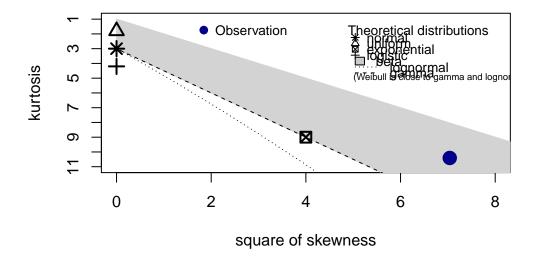
```
ks.test(dados, "pgamma", 4.697015, 2.448444, exact=FALSE)
```

One-sample Kolmogorov-Smirnov test

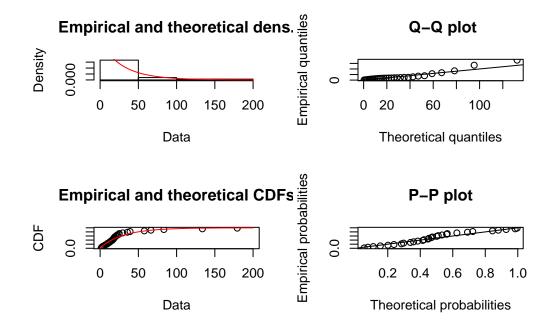
```
data: dados
D = 0.094125, p-value = 0.9531
alternative hypothesis: two-sided
```

c)

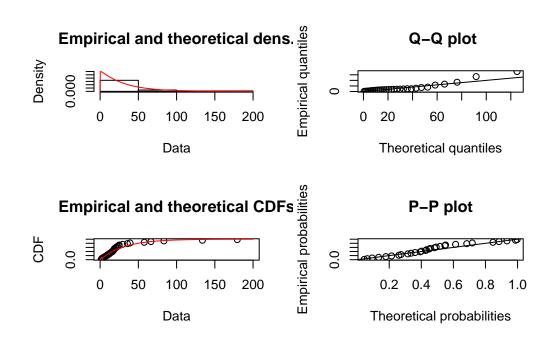
Cullen and Frey graph



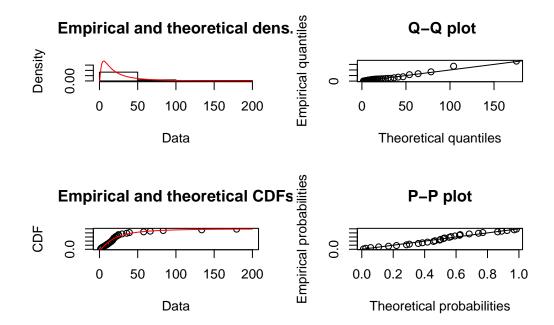
Weibull:



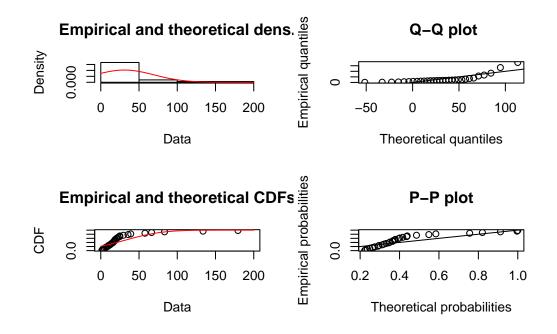
Gamma:



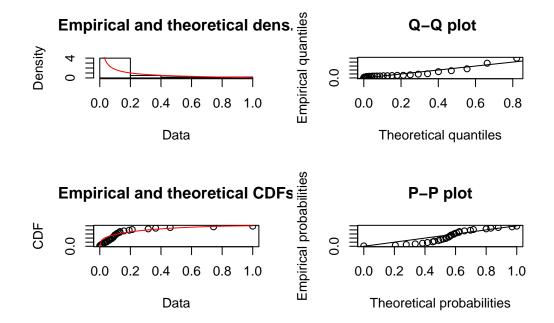
Lognormal:



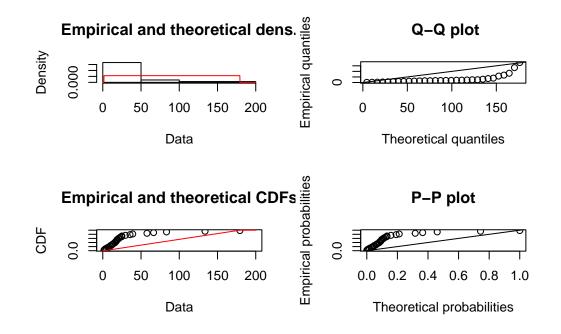
Normal:



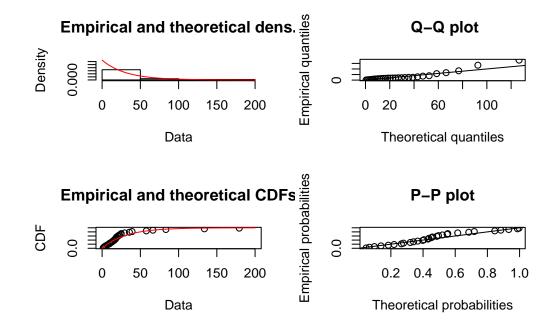
Beta:



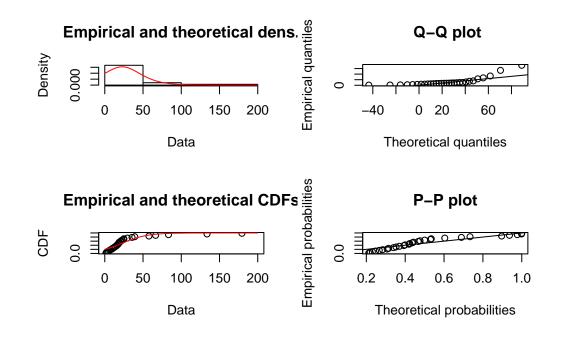
Uniforme:



Exponencial:



Logística:



Critério de Informação de Akaike

Weibull: 269.726392071423 Gamma: 269.854267184135 Lognormal: 265.910553623527 Normal: 308.549444866565

Beta: NaN

Uniforme: 314.856917728505 Exponencial: 267.86587199743 Logística: 297.626998043809

A distribuição que apresenta menor Critério de Informação de Akaike é a **Lognormal**. Portanto, realiza-se o teste de Kolmogorov-Smirnov e não se rejeita a hipótese de que os dados seguem a distribuição **Lognormal**, com um nível de significância de 5%.

```
fitdist(dados, "lnorm", method="mle")
Fitting of the distribution ' lnorm ' by maximum likelihood
Parameters:
        estimate Std. Error
meanlog 2.869537 0.1971287
sdlog
        1.079718 0.1393905
  ks.test(dados, "plnorm", 2.869537, 1.079718, exact=FALSE)
    One-sample Kolmogorov-Smirnov test
data: dados
D = 0.10729, p-value = 0.8802
alternative hypothesis: two-sided
d)
  dados <- c(4.391658, 5.364267, 10.707930, 5.431008, 6.904122, 6.960462,
   → 12.741468, 8.094473, 7.255829, 8.434530, 9.747057, 6.440681,

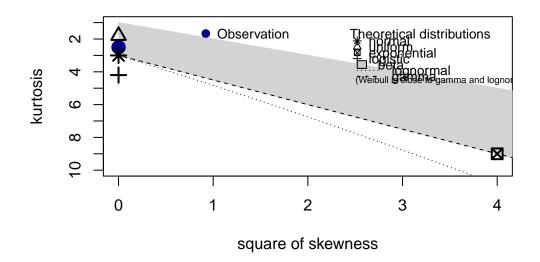
→ 7.623020, 9.276933, 8.711818, 5.250229, 6.482474, 3.478216,

   \rightarrow 9.717008, 9.317296, 9.011653, 11.758927, 10.844472, 9.644711,

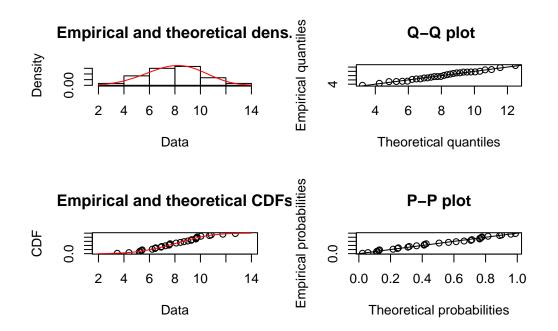
→ 7.541715, 7.561009, 10.034726, 9.654606, 6.222452, 5.207637)

  id_dist(dados);
```

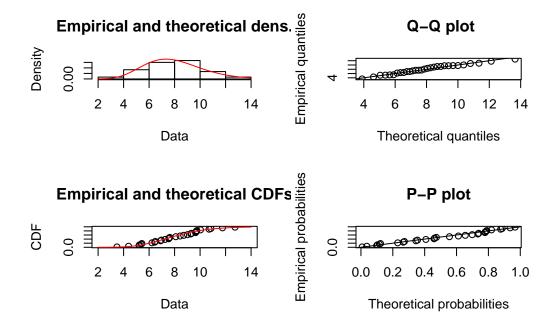
Cullen and Frey graph



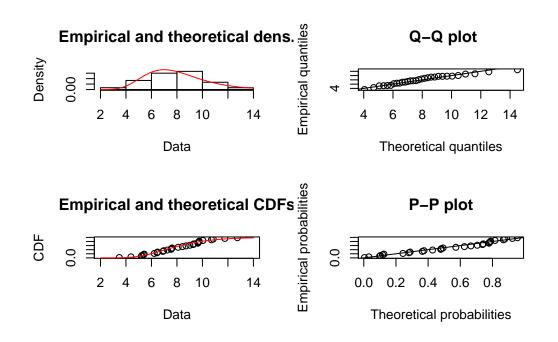
Weibull:



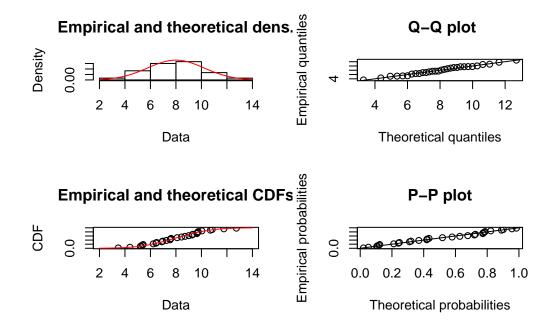
Gamma:



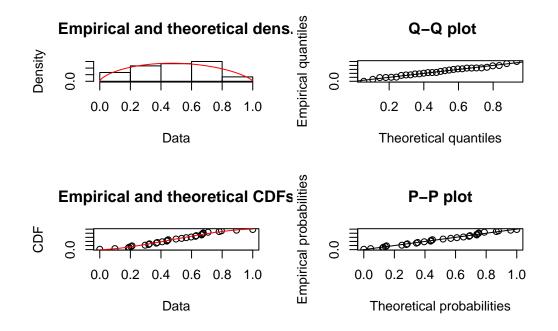
Lognormal:



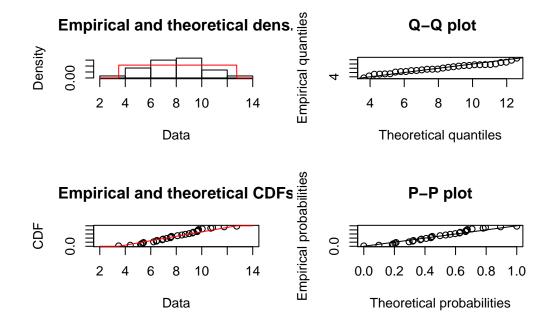
Normal:



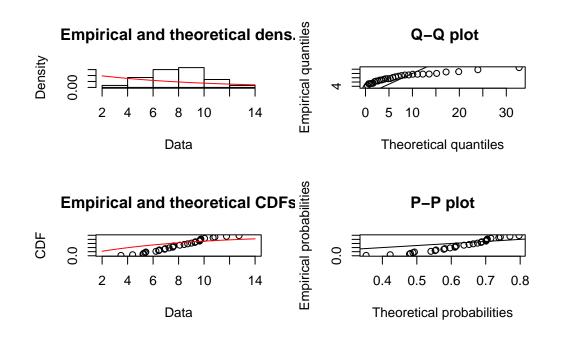
Beta:



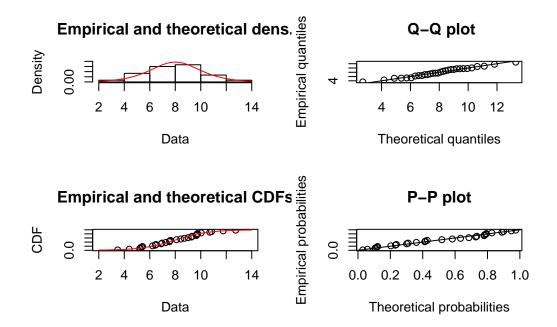
Uniforme:



Exponencial:



Logística:



Critério de Informação de Akaike

Weibull: 136.371061137677 Gamma: 137.524488802914 Lognormal: 139.025879465118 Normal: 136.6818515043

Beta: Inf

Uniforme: 137.563310494661 Exponencial: 186.719570908607 Logística: 138.263602150104

A distribuição que apresenta menor Critério de Informação de Akaike é a **Weibull**. Portanto, realiza-se o teste de Kolmogorov-Smirnov e não se rejeita a hipótese de que os dados seguem a distribuição **Weibull**, com um nível de significância de 5%.

```
fitdist(dados, "weibull", method="mle")
```

Fitting of the distribution 'weibull 'by maximum likelihood Parameters:

estimate Std. Error shape 4.057284 0.5782002 scale 8.819386 0.4185798

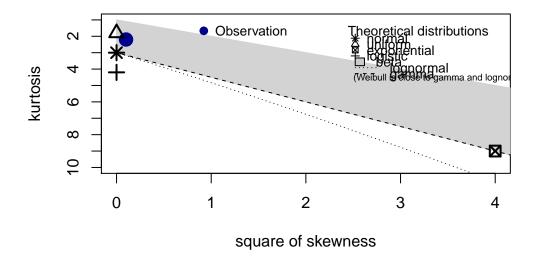
```
ks.test(dados, "pweibull", 4.057284, 8.819386, exact=FALSE)
```

One-sample Kolmogorov-Smirnov test

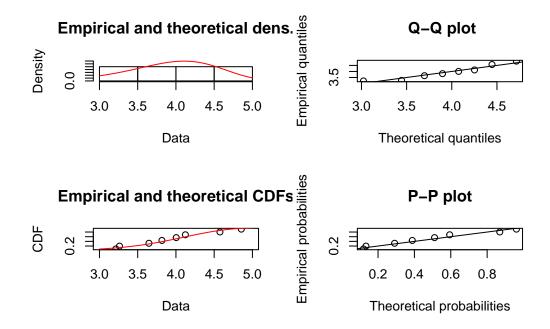
```
data: dados
D = 0.074926, p-value = 0.996
alternative hypothesis: two-sided
```

e)

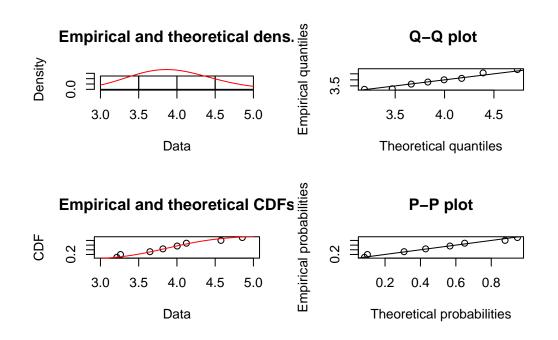
Cullen and Frey graph



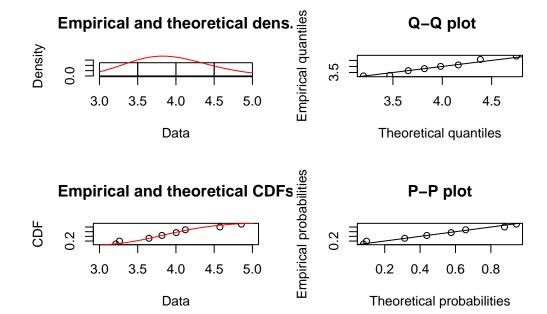
Weibull:



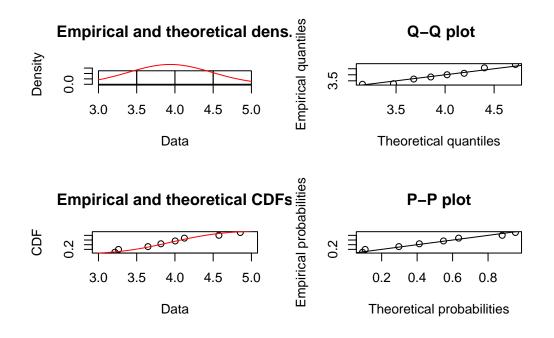
Gamma:



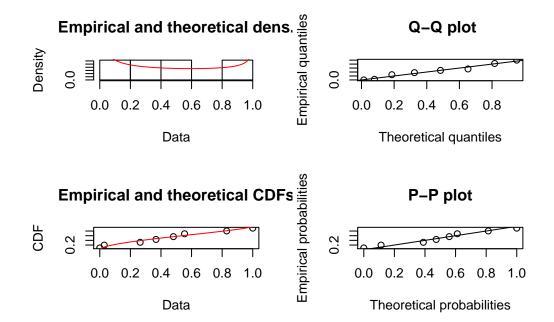
Lognormal:



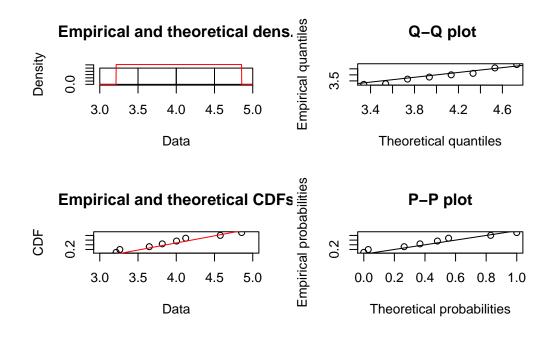
Normal:



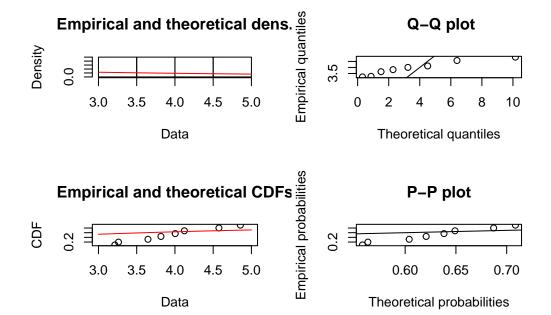
Beta:



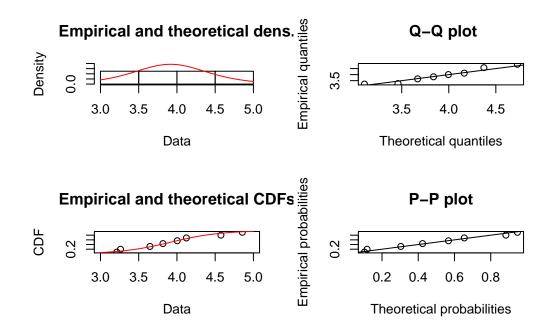
Uniforme:



Exponencial:



Logística:



Critério de Informação de Akaike

Weibull: 17.4848067022608 Gamma: 16.7857780075344 Lognormal: 16.7480979226041 Normal: 16.9562031603306

Beta: -Inf

Uniforme: 11.9228258278989 Exponencial: 39.9275403392093 Logística: 17.5514378926189

A distribuição que apresenta menor Critério de Informação de Akaike é a **Uniforme**. Portanto, realiza-se o teste de Kolmogorov-Smirnov e não se rejeita a hipótese de que os dados seguem a distribuição **Uniforme**, com um nível de significância de 5%.

```
fitdist(dados, "unif", method="mle")
```

Fitting of the distribution ' unif ' by maximum likelihood Parameters:

estimate Std. Error min 3.214129 $$\rm NA$$ max 4.854917 $$\rm NA$$

```
ks.test(dados, "punif", 3.214129, 4.854917, exact=FALSE)
```

One-sample Kolmogorov-Smirnov test

data: dados

D = 0.22087, p-value = 0.83

alternative hypothesis: two-sided